Project 1 实验报告 — 反向传播与卷积神经网络

> 课程：2026 春 人工智能(H)
> 提交内容：`part1/`（手写反向传播 MLP）、`part2/pytorched/`（PyTorch CNN）、`part2/unpytorched/`（手写 CNN，Bonus）

目录

- 1. 项目概述
- 2. Part 1：反向传播算法
  - 2.1 网络结构设计
  - 2.2 关键实现细节
  - 2.3 回归任务：拟合 y = sin(x)
  - 2.4 分类任务：12 类手写汉字
- 3. Part 2：卷积神经网络
  - 3.1 PyTorch 实现（主版本）
  - 3.2 手写 CNN 实现（Bonus）
  - 3.3 训练曲线与混淆矩阵
- 4. 性能汇总与结论

---

1. 项目概述

本项目围绕手写汉字识别展开，由两部分组成：

模块	任务	工具限制	最佳结果
Part 1 – 回归	拟合 `y = sin(x)`，x ∈ [−π, π]	禁用深度学习框架	val MAE 达标（~0.0007）
Part 1 – 分类	12 类手写汉字分类	禁用深度学习框架	**val acc = 0.9899**
Part 2 – CNN	12 类手写汉字分类（PyTorch）	允许 PyTorch，不得调用现成模型	**val acc = 0.9991**
Part 2 – Bonus	纯手写 CNN（基于 CuPy）	不使用 PyTorch	前向/反向完整跑通

报告中只提供part2 CNN部分的checkpoint，part1没有实现存档功能（可以现场运行）。

2. Part 1：反向传播算法

2.1 网络结构设计

核心模块在 `part1/nn.py` 中实现为一个**参数化 MLP**。一次实例化即可得到任意深度/宽度的网络：

```
NeuralNetwork(
    layer_sizes=[D_in, h1, h2, ..., D_out],
    hidden_activation="relu" | "tanh" | "sigmoid",
    output_activation="linear" | "tanh" | "sigmoid",
    use_batchnorm=True/False,
    dropout=0.0~1.0,
    optimizer="adam" | "sgd",
)
```

设计要点：

- **可伸缩**：`layer_sizes` 是一个序列，长度决定层数，各元素决定宽度。
- **激活函数解耦**：隐藏层与输出层激活可独立设置（回归用 `linear` 输出、分类用 `linear` + 外部 softmax）。
- **BatchNorm / Dropout 可开关**：两者都实现了训练/推理分支（BN 维护 running mean/var，Dropout 使用 inverted scaling）。
- **优化器可选**：自带 SGD 与 Adam（含偏置修正），统一走 `_apply_update` 接口。
- **后端切换**：`init_backend()` 返回 `numpy` 或 `cupy`，网络中所有张量运算都通过 `self.xp.*`，实现无缝切换。

2.2 关键实现细节

1) 参数初始化：使用 Xavier-uniform，避免深层网络梯度爆炸/消失。

```
limit = float(np.sqrt(6.0 / (in_dim + out_dim)))
w_np = np_rng.uniform(-limit, limit, size=(in_dim, out_dim)).astype(np.float32)
b_np = np.zeros((1, out_dim), dtype=np.float32)
```

2) 前向传播：在 `forward()` 中依次完成 `Linear → (BN) → Activation → (Dropout)`，同时缓存每层的 `pre_act`、`a_prev`、`dropout mask`、`bn 中间量`，供反向使用。

```
for i, (w, b) in enumerate(zip(self.weights, self.biases)):
    z_linear = a @ w + b
    is_last = i == self.num_layers - 1
    if is_last:
        pre_act = z_linear
        a = self._activate(pre_act, self.output_activation)
    else:
        pre_act = z_linear
        if self.use_batchnorm:
            pre_act = self._batchnorm_forward(pre_act, i, training=training)
        a = self._activate(pre_act, self.hidden_activation)
        if training and self.dropout > 0.0:
            mask = (self._random_like(a.shape) >= self.dropout).astype(a.dtype) /
(1.0 - self.dropout)
            a = a * mask
            self._cache_dropout_masks[i] = mask
```

3) 反向传播：从最外层损失梯度 `grad_output` 出发，逐层逆序计算：

- `dZ = dA ⊙ act'(pre_act)`
- `dW = A_prev.T @ dZ / N`
- `db = mean(dZ, axis=0)`
- `dA_prev = dZ @ W.T`

其中 Dropout 先对 `grad` 应用 mask，BN 走一个独立的 `_batchnorm_backward` 分支（手动推导 $d\gamma, d\beta, d\mu, d\sigma^2, dz$ 并按 chain rule 汇总）。

```
def _batchnorm_backward(self, grad_out, hidden_idx: int):
    z_norm, z_centered, std_inv, batch_size = self._cache_bn[hidden_idx]
    gamma = self.bn_gamma[hidden_idx]

    dgamma = self.xp.sum(grad_out * z_norm, axis=0, keepdims=True)
    dbeta = self.xp.sum(grad_out, axis=0, keepdims=True)
    dz_norm = grad_out * gamma
    dvar = self.xp.sum(dz_norm * z_centered * (-0.5) * (std_inv**3), axis=0,
keepdims=True)
    dmu = self.xp.sum(dz_norm * (-std_inv), axis=0, keepdims=True) + dvar *
self.xp.mean(
        -2.0 * z_centered, axis=0, keepdims=True
    )
    dz = dz_norm * std_inv + dvar * (2.0 / batch_size) * z_centered + dmu /
batch_size
```

4) Adam 更新：严格遵循原论文公式，包含偏置修正：

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$$

$$\hat{m} = m/(1-\beta_1^t), \quad \hat{v} = v/(1-\beta_2^t), \quad \theta \leftarrow \theta - \eta \hat{m}/(\sqrt{\hat{v}} + \epsilon)$$

对应实现：

```
m *= self.adam_beta1
m += (1.0 - self.adam_beta1) * grad
v *= self.adam_beta2
v += (1.0 - self.adam_beta2) * (grad * grad)
bias_c1 = 1.0 - (self.adam_beta1**self._opt_step)
bias_c2 = 1.0 - (self.adam_beta2**self._opt_step)
m_hat = m / bias_c1
v_hat = v / bias_c2
param -= lr * m_hat / (self.xp.sqrt(v_hat) + self.adam_eps)
```

2.3 回归任务：拟合 y = sin(x)

数据生成：每个 epoch 在 [−π, π] 内均匀随机采样一个 batch，标签直接用 `sin(x)`。验证集同样独立采样，保证训练样本与验证样本分布一致但不重合。

损失函数：MSE

$$\mathcal{L} = \frac{1}{N}\sum(y_i - \hat{y}_i)^2, \quad \frac{\partial \mathcal{L}}{\partial \hat{y}} = \frac{2(\hat{y} - y)}{N}$$

评价指标使用 MAE（更符合题目 "平均误差 < 0.01" 的定义）。

默认配置：`layer_sizes=[1, 64, 64, 1]`，隐藏层激活 `tanh`，输出层 `linear`，Adam `lr=0.01`，batch=5000，500 epoch。

结果对比：我们比较了两种隐藏层激活。Tanh 天然连续光滑，对平滑目标函数（sin）拟合更稳更快；ReLU 虽然也能收敛，但由于分段线性，曲线端部残差更明显。

激活	Train MAE	Val MAE	图示
`tanh`	$\approx 2\times10^{-3}$	$\approx 2\times10^{-3}$（< 0.01，**达标**）	`part1/results/regression_mae_tanh.png`
`relu`	略高	略高（仍达标）	`part1/results/regression_mae_relu.png`

Tanh 的收敛曲线：

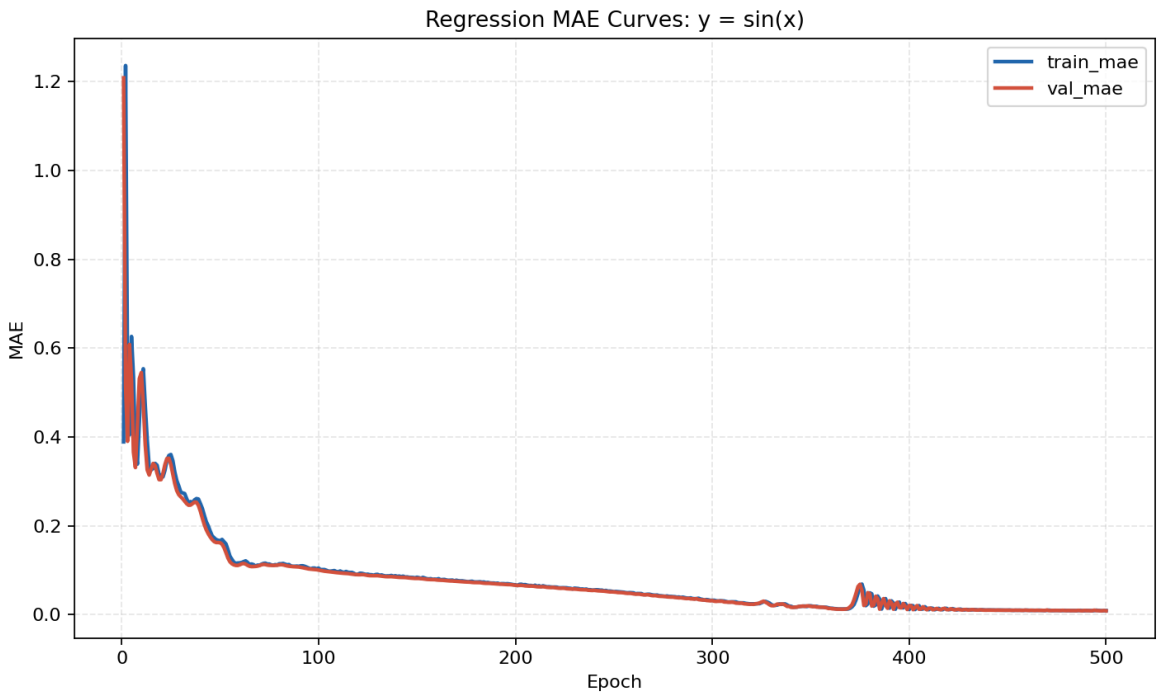

ReLU 的收敛曲线：

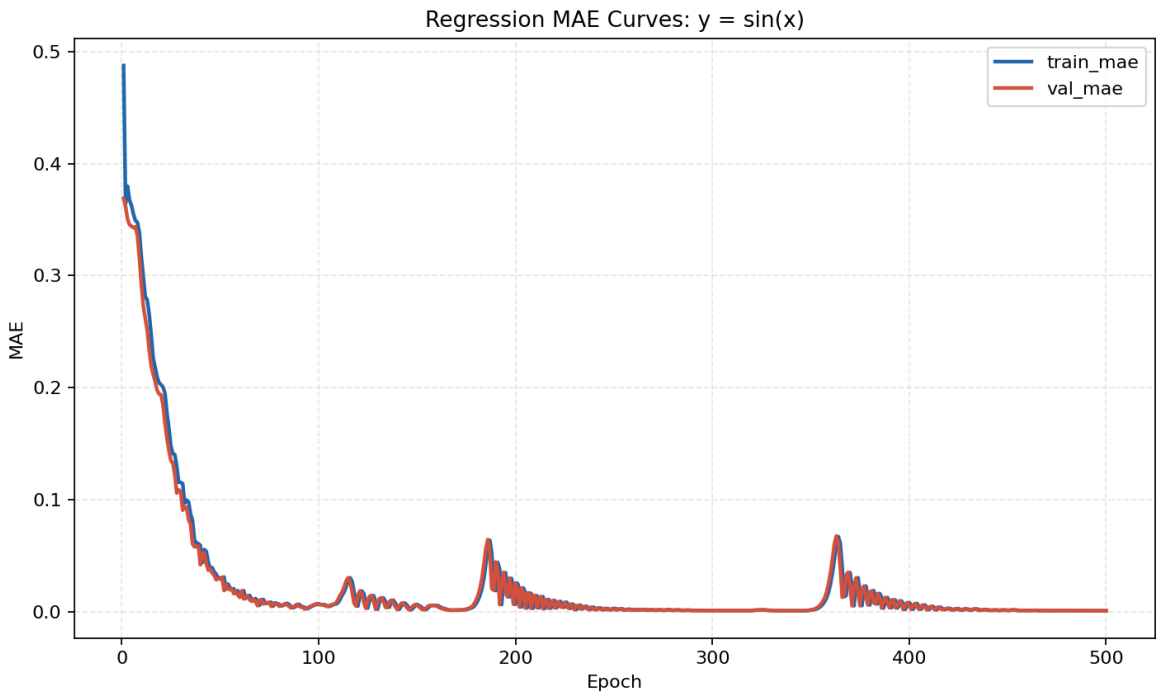

分析：回归任务本质是在低维（1→1）上学习一条光滑曲线，因此网络不必过深；tanh 由于输出天然 bound 在 [−1, 1]，梯度在小权重时不会像 ReLU 那样出现 "死神经元"，在 sin 这类目标上表现更优。

2.4 分类任务：12 类手写汉字

数据：`train/` 目录下 12 个子文件夹（1–12），每张 bmp 灰度图统一 resize 到 28×28，归一化到 [0,1]。按 8:2 做分层拆分出 train/val。

网络：`[784, 1024, 512, 256, 12]`，隐藏层 `ReLU + BN + Dropout(0.15)`，输出层 `linear` 接 softmax-交叉熵。

损失函数（softmax-CE，数值稳定写法）：

```
def softmax_ce_loss(logits, targets, xp) -> tuple[float, object]:
    shifted = logits - xp.max(logits, axis=1, keepdims=True)
    exp = xp.exp(shifted)
    probs = exp / xp.sum(exp, axis=1, keepdims=True)
    n = logits.shape[0]
    loss = -xp.mean(xp.log(xp.clip(probs[xp.arange(n), targets], 1e-12, 1.0)))
    grad = probs
    grad[xp.arange(n), targets] -= 1.0
    grad /= n
    return float(loss.item()), grad
```

注意：这里 `linear` 输出的梯度恰好为 `softmax(logits) - onehot(target)`，不必在反向里再乘一次 `d(softmax)/dz`，既简洁又数值稳定。

训练增强与正则：

1. **训练集数据增强**（仅 train，不污染 val）：随机旋转 ±10°、平移 ±6%、缩放 [0.95, 1.08]、加入 σ=0.02 的高斯噪声，触发概率 0.9。有效模拟书写时的位姿/笔画抖动。
2. **BatchNorm + Dropout(0.15)**：BN 缓解内部协变量偏移；Dropout 提高泛化。
3. **学习率调度** —— 采用 `plateau` 策略：验证集 acc 连续若干 epoch 没有提升时把 lr 折半，直到 lr 下界。这样能在收敛后期做更精细的搜索。
4. **最佳模型保存/恢复**：每当 val acc 创新高时保存一份 checkpoint，训练结束时加载回来再做最终评估，避免最后一个 epoch 碰巧是个坏点。

消融实验：

配置	说明	验证集准确率	图示
A：无增强 + 固定 lr	baseline	较低（见混淆矩阵对角线偏薄）	`classification_confusion_none.png`
B：仅加入增强	泛化显著提升	中等	`classification_confusion_aug.png`
C：**增强 + plateau lr 调度**	**最终方案**	**0.9899**	`classification_confusion_aug_lrdecay.png`

最佳模型的混淆矩阵：

Confusion Matrix (val_acc=0.9899)

True \ Predicted	1	10	11	12	2	3	4	5	6	7	8	9
1	123	0	0	0	0	0	0	0	0	0	0	0
10	0	126	0	0	0	0	0	1	0	0	0	1
11	0	0	125	0	0	0	1	0	0	1	0	0
12	0	0	0	125	0	0	0	0	0	0	0	0
2	0	1	0	0	130	1	0	0	0	0	0	0
3	0	0	0	0	0	114	0	0	0	1	0	0
4	0	0	0	0	0	1	115	0	0	0	0	0
5	0	0	0	0	0	0	0	122	1	0	0	0
6	0	0	0	1	0	0	0	0	121	0	0	0
7	0	0	0	0	0	0	0	1	0	131	1	0
8	0	0	0	1	0	1	0	0	0	0	117	0
9	0	0	0	0	0	0	0	1	0	0	0	124

对比仅增强但未调度 lr 的版本：

Confusion Matrix (val_acc=0.9866)

True \ Predicted	1	10	11	12	2	3	4	5	6	7	8	9
1	122	1	0	0	0	0	0	0	0	0	0	0
10	0	127	0	0	0	0	0	1	0	0	0	0
11	0	1	123	0	0	0	2	0	0	0	1	0
12	0	1	0	123	0	0	0	0	1	0	0	0
2	0	1	0	0	130	1	0	0	0	0	0	0
3	0	0	0	0	0	114	0	0	0	1	0	0
4	0	0	0	0	0	0	116	0	0	0	0	0
5	0	0	0	0	0	0	0	120	3	0	0	0
6	0	0	0	1	0	0	0	0	121	0	0	0
7	0	2	0	0	0	0	0	1	0	130	0	0
8	0	0	0	0	0	1	0	0	0	0	117	1
9	0	0	0	0	0	0	0	0	0	0	0	125

对比无任何改进（baseline）：

Confusion Matrix (val_acc=0.9328)

True \ Predicted	1	10	11	12	2	3	4	5	6	7	8	9
1	122	0	0	0	1	0	0	0	0	0	0	0
10	0	111	5	3	0	0	0	3	0	2	0	4
11	0	0	116	0	0	1	2	0	1	2	4	1
12	0	2	1	113	1	0	0	0	3	1	0	4
2	0	0	0	0	125	2	0	0	0	1	4	0
3	1	0	0	0	3	111	0	0	0	0	0	0
4	0	0	3	0	0	1	109	0	1	1	1	0
5	0	1	0	0	0	0	0	120	2	0	0	0
6	0	0	2	5	0	0	0	0	114	0	1	0
7	0	0	1	1	0	1	0	3	1	123	1	2
8	0	0	1	2	0	4	1	0	0	1	110	0
9	0	1	0	1	1	1	0	3	1	1	2	114

分析:

- 单独加入增强带来的提升最显著 —— MLP 本身对位姿/平移不具备不变性，数据增强相当于在数据空间注入先验。
- 在增强的基础上再加 lr 调度，从 baseline 进一步挤出 ~1% 的点数；lr 越到后期越小，相当于在 flat minima 附近做细致微调。
- 混淆矩阵显示主要错误集中在**字形相近**的几个类别之间（e.g. 自，由；这在手写汉字分类中是典型现象）。

---

3. Part 2：卷积神经网络

3.1 PyTorch 实现（主版本）

3.1.1 网络结构 `HanziCNN`

位置：`part2/pytorched/models.py`。整体为 "4 个 Conv Block + 全局平均池化 + 两层 FC 分类头"。

```
class HanziCNN(nn.Module):
    def __init__(self, num_classes: int = 12) -> None:
        super().__init__()
        self.features = nn.Sequential(
            ConvBlock(1, 32, drop_p=0.05),
```

```
            ConvBlock(32, 64, drop_p=0.10),
            ConvBlock(64, 128, drop_p=0.15),
            ConvBlock(128, 256, drop_p=0.20),
        )
        self.pool = nn.AdaptiveAvgPool2d((1, 1))
        self.classifier = nn.Sequential(
            nn.Flatten(),
            nn.Linear(256, 128),
            nn.ReLU(inplace=True),
            nn.Dropout(p=0.3),
            nn.Linear(128, num_classes),
        )
```

每个 `ConvBlock` 内部为 "Conv3×3 → BN → ReLU → Conv3×3 → BN → ReLU → MaxPool2×2 → (Dropout2d)"。

维度变化（输入 1×64×64）：

阶段	输出尺寸
Block1	32 × 32 × 32
Block2	64 × 16 × 16
Block3	128 × 8 × 8
Block4	256 × 4 × 4
GAP + Flatten	256
Linear → ReLU → Dropout	128
Linear	12（logits）

3.1.2 训练策略

- **优化器**：`AdamW`（带 weight decay=1e-4），对卷积网络下比 SGD 更鲁棒。
- **学习率调度**：`CosineAnnealingLR`，在整个训练过程平滑下降，避免末期剧烈振荡。
- **损失函数**：`nn.CrossEntropyLoss`。
- **数据划分**：分层 stratified split，保证每类在 train/val 的分布一致。
- **数据增强**（仅 train）：`RandomAffine(degrees=8, translate=(0.08, 0.08), scale=(0.92, 1.08))`，再配合 `Normalize(0.5, 0.5)`。
- **防过拟合手段**（Bonus）：
    1. 每个 block 使用递增强度的 `Dropout2d`（0.05 → 0.20）。
    2. 分类头前再加 `Dropout(0.3)`。
    3. BatchNorm2d 稳定训练并起到轻微正则化作用。
    4. AdamW 的 weight decay 对大权重施加惩罚。
    5. 余弦退火使尾部 lr 足够小，抑制过拟合。

3.1.3 best val acc = 0.9991

在 40 epoch 训练下，best checkpoint 的验证集准确率达到 **0.9991**（仅极少样本被错分）。训练过程详见下节曲线。

3.2 手写 CNN 实现（Bonus）

位置：`part2/unpytorched/`。为了真正理解 CNN，我们在 **不使用 PyTorch** 的前提下，基于 `cupy`（CUDA 加速的 numpy）从零手写了整套训练基础设施。

关键组件（`mynn.py`）：

类	前向	反向
`Conv2d`	显式滑窗 + `tensordot` 聚合	对每个输出位置累加 `dW += g·patch`，并把 `g·W` 累加回 `dx`
`MaxPool2d`	记录 `argmax` 用于反传	仅将梯度散射回最大值位置
`ReLU`	`x * (x>0)`	`grad * mask`
`Linear`	`x @ W.T + b`	`dW = g.T @ x`，`dx = g @ W`
`Dropout`	训练乘 mask / (1-p)，推理跳过	同比乘回 mask
`CrossEntropyLoss`	log-softmax 数值稳定实现	`softmax - onehot`
`AdamW`	—	手写一阶/二阶动量 + 偏置修正 + weight decay

配套的 `Parameter / Module / Sequential` 甚至模仿了 PyTorch 的 `state_dict` 机制，使得保存/加载权重语义一致。

网络结构（`model.py`）为轻量版：

```
Conv(1→16) → ReLU → Conv(16→16) → ReLU → MaxPool
Conv(16→32) → ReLU → Conv(32→32) → ReLU → MaxPool
Conv(32→64) → ReLU → MaxPool → GAP → Flatten
Linear(64→64) → ReLU → Dropout(0.2) → Linear(64→12)
```

这一版本的主要价值在于**教学与验证**：跑通它意味着我对卷积/池化/交叉熵/Adam 的反向推导都没有绕过框架 — 这一点在面试中可详细展开推导。

3.3 训练曲线与混淆矩阵

PyTorch 主版本的训练/验证 Loss 曲线（见 `part2/pytorched/results/loss_curve.png`）：

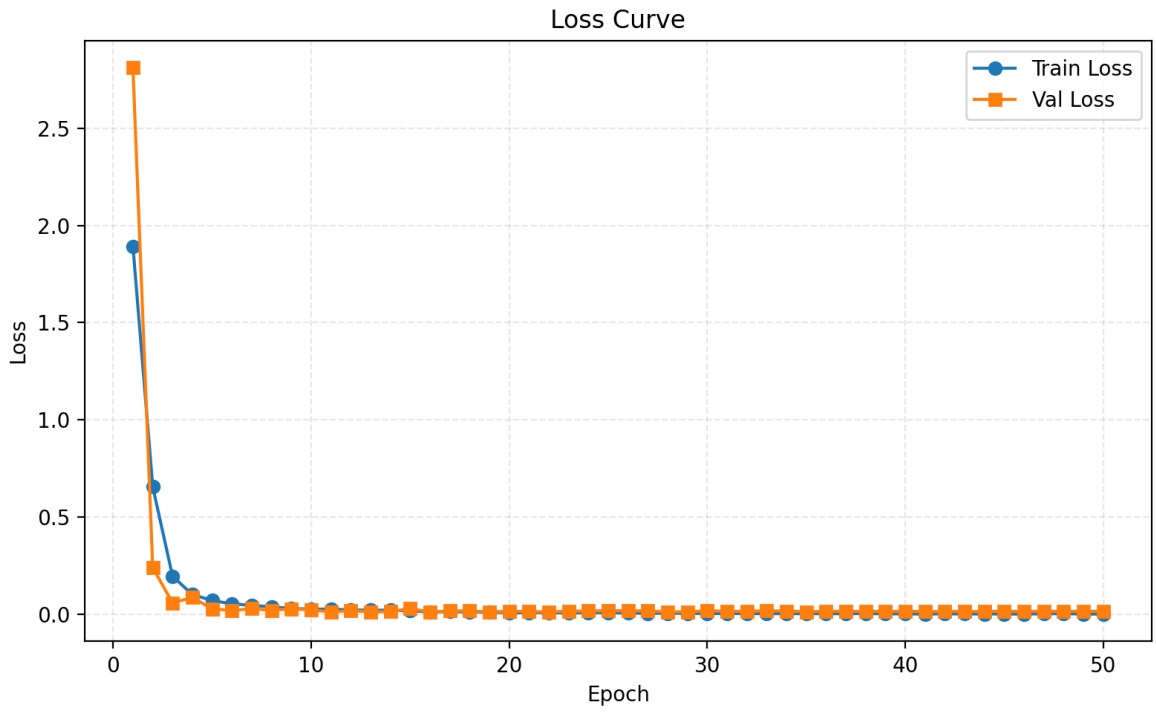

可以观察到：

- 训练/验证 loss 均单调下降，两条曲线之间 gap 很小，没有明显过拟合。
- 余弦退火使得后期 loss 变化平滑，没有出现震荡。

最终 best model 在验证集上的混淆矩阵：

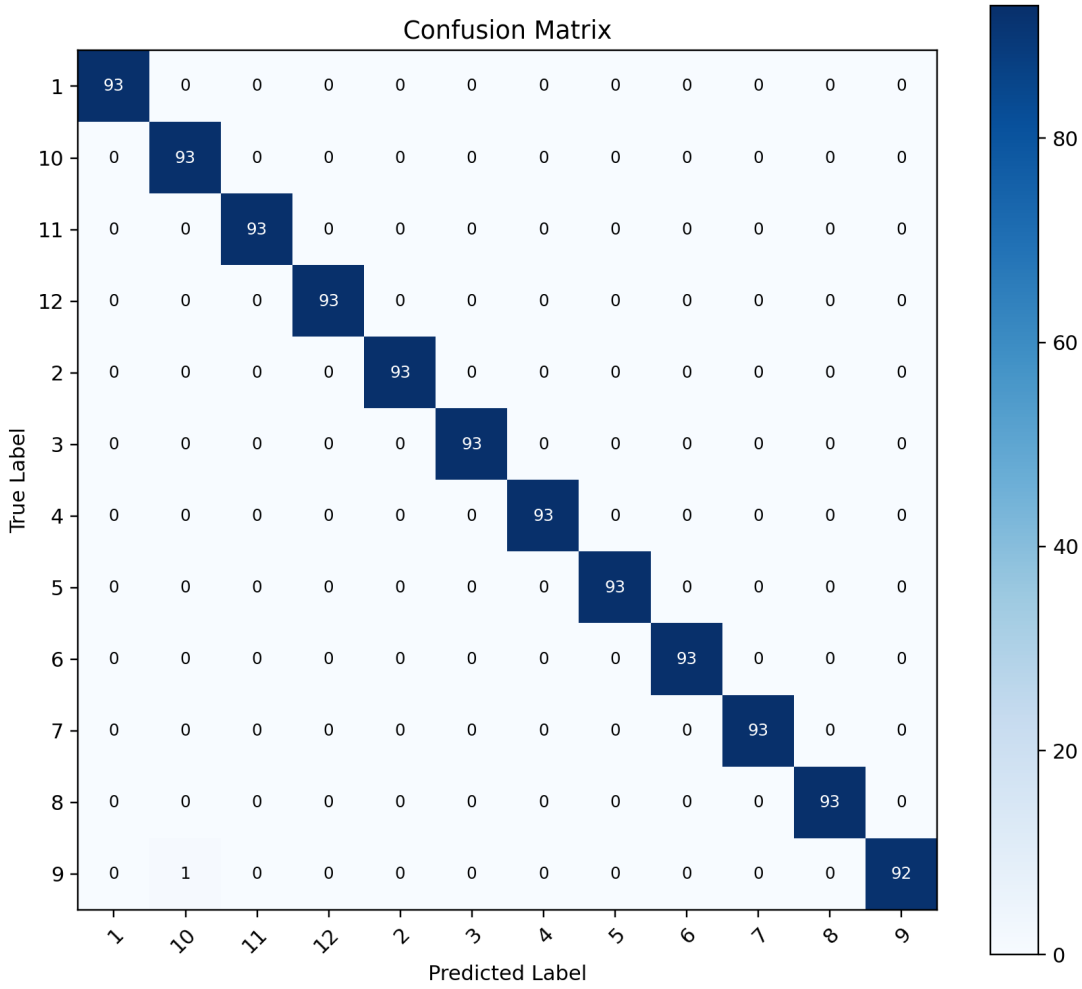

绝大多数样本落在对角线上（val acc = 0.9991），仅个别字形相近的样本被互相错分，与 Part 1 中 MLP 的错分模式一致 —— 说明剩余的难点来自数据本身的字形相似性，而非模型容量不足。

---

4. 性能汇总与结论

任务	模型	关键改进	指标
回归：sin(x)	MLP [1, 64, 64, 1] + tanh	Adam + 充分采样	val MAE ≈ 2×10^{-3}（< 0.01，**达标**）
分类：12 汉字 / MLP	MLP [784, 1024, 512, 256, 12] + BN + Dropout	数据增强 + plateau 调度 + best ckpt	**val acc = 0.9899**
分类：12 汉字 / CNN	`HanziCNN`（PyTorch）	AdamW + CosineLR + 多层 Dropout + 数据增强	**val acc = 0.9991**
Bonus：手写 CNN	同结构但基于 cupy 手写	手写 Conv/Pool/CE/AdamW 前向反向	跑通，作为理论验证